

gtcf를 통해 해결하고자 하는 문제점과 해결방법

- gtcf는 gnn 기반의 CF 모델들이 **unreliable**한 interaction을 고려하지 않았다는 점을 한계점으로 지적했다. 이 문제를 해결하기 위해 **Smoothing Assumption**을 [수식1]과 같이 설정했다. 이 최적화 문제를 풀게 되면 임베딩 매트릭스에 대한 [수식2]와 같은 **iterative solver**를 얻을 수 있다. [수식2]를 이용해 k번째 레이어의 임베딩 매트릭스, 파이널 임베딩을 계산할 수 있다. model prediction과 model train은 기존 gnn 기반 CF모델과 동일하게 내적을 사용하고, BPR Loss를 계산해 그래디언트를 역전파시킨다.

Smoothing Assumption을 통해 user-item interaction 상의 smoothness를 **proper**하게 모델링할 수 있다. 이는 두 임베딩이 유사할 때는 더 유사해지도록 임베딩을 학습시키고, 분명한 차이가 존재할 때는 그 차이를 유지하는 것을 의미한다.

$$\arg \min_{\mathbf{E} \in \mathbb{R}^{(n+m) \times d}} \frac{1}{2} \|\mathbf{E} - \mathbf{E}_{in}\|_F^2 + \lambda \|\tilde{\Delta} \mathbf{E}\|_1,$$


[수식1]

$$\begin{cases} \tilde{\mathbf{E}}^{k+1} = \mathbf{E}_{in} - \tilde{\Delta}^\top \mathbf{Y}^k \\ \tilde{\mathbf{Y}}^{k+1} = \mathbf{Y}^k + \frac{1}{2} \tilde{\Delta} \tilde{\mathbf{E}}^{k+1} \\ \mathbf{Y}^{k+1} = \text{sign}(\tilde{\mathbf{Y}}^{k+1}) \min(|\tilde{\mathbf{Y}}^{k+1}|, \lambda) \end{cases}$$

Output: $\mathbf{E}^{k+1} = \mathbf{E}_{in} - \tilde{\Delta}^\top \mathbf{Y}^{k+1}$

[수식2]

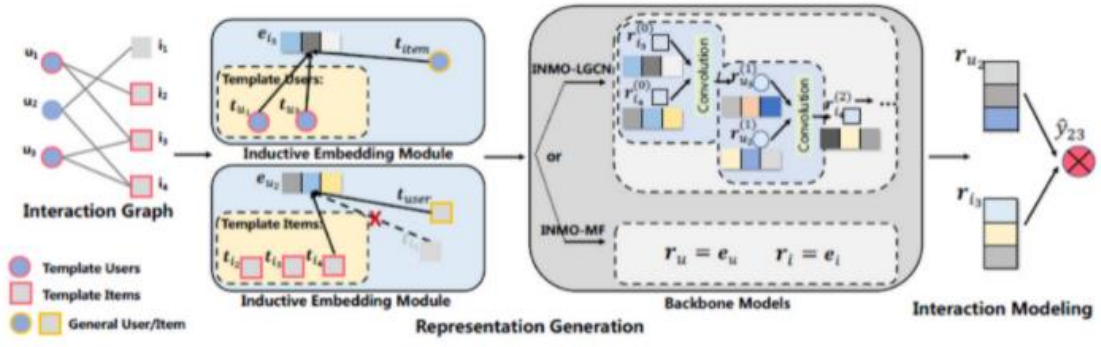
inmo모듈을 통해 해결하고자 하는 문제점과 해결방법

- inmo는 기존 CF 모델들이 **inductive**( transductive) 시나리오를 해결할 수 없다는 점을 한계점으로 지적한다. inductive 시나리오를 해결할 수 있음은 새로운 노드(user or item) 혹은 간선(interaction)이 추가되었을 때 **re-training** 없이 추가된 정보들을 prediction에 이용할 수 있도록 모델링하는 것을 의미한다. 실세계는 지속적으로 새로운 노드, 간선이 추가되기 때문에 **inductivity ability**를 갖추는 것은 유의미(실용적)하다.

inmo는 전처리 모듈로써 사용될 수 있다. 본 연구에서는 Light-GCN과 Matrix Factorization에 inmo 전처리 모듈을 추가함으로써 **inductivity ability**를 획득했다. Light-GCN에 inmo 모듈을 추가한 architecture는 [그림1]과 같다. 메인 아이디어는 Embedding Initialization 과정을 통해 얻어지는 임베딩 **look-up 테이블**을 inmo로 대체하는 것이다. 이는 **inductive**한 방식으로 임베딩을 생성하는 것을 의미한다.

- inductive한 방식으로 임베딩을 생성하기 위해서는 **template users/items**를 설정하는 것이 중요하다. template users/items를 설정하는 것의 유효성과 메커니즘은 [정리1]과 [정리2]를 통해 입증되었다. 임베딩은 [수식3]을 통해 생성된다. [그림1]을 이용해 [수식3]을 다시 보게 되면, 유저의 임베딩은 유저의 이웃 노드들과 템플릿 아이템들의 **교집합**으로 정규화되며 실질적으로 유저의 임베딩을 생성하는데 영향을 끼치는 임베딩들은 유저와 이웃관계의 아이템들과 템플릿 아이템의 **교집합**에 속하는 **아이템**들이다. 이때 유저의 **global characteristics** 정보를 이용하기 위해 템플릿 유저의 임베딩을 이용한다.

임베딩 생성을 위한 손실함수로는 BPR Loss와 함께 **self-enhanced Loss**를 이용한다. 따라서 [수식4]의 손실함수를 이용해서 모델을 최적화한다.



[그림1]

THEOREM 4.1. Assuming the original MF can achieve a matrix factorization error ϵ on the interaction matrix Y , then there exists a solution for INMO-MF such that its error is less than or equal to ϵ , when INMO takes all users/items as the template users/items.

[정리1]

THEOREM 4.2. When selecting those users u_j with the largest $|s_j^u|_2^2 \sum_{i \in \mathcal{N}_{u_j}} |\mathcal{N}_i|$ as the template users, INMO minimizes an upper bound of the additional error caused by ignoring non-template users.

[정리2]

$$e_u = \frac{1}{(|\mathcal{N}_u \cap I_{tem}| + 1)^\alpha} \left(\sum_{i \in \mathcal{N}_u \cap I_{tem}} t_i + t_{user} \right),$$

$$e_i = \frac{1}{(|\mathcal{N}_i \cap U_{tem}| + 1)^\alpha} \left(\sum_{u \in \mathcal{N}_i \cap U_{tem}} t_u + t_{item} \right),$$

[수식3]

$$\mathcal{L} = \mathcal{L}_{BPR} + \beta \mathcal{L}_{SE}$$

[수식4]

두 기법을 결합하고자 하는 동기: gtcf의 한계점

gtcf는 inductive 시나리오를 해결하기 위해 설계된 모델이 아니다. 따라서 transductive 시나리오에서는 우수한 성능을 보였지만 inductive 시나리오에서는 그 성능이 입증되지 않았다. 하지만 inmo에서 밝힌 바와 같이 실세계의 문제 상황을 더 적합하게 표현한 시나리오는 inductive 시나리오다. 따라서 gtcf에 inmo 모듈을 더해 inductive 시나리오를 해결하고자 하는 것은 유의미하다.

두 기법을 결합했을 때 얻게되는 이득과 이에 대한 논리적 증거

- ∴ [표1]과 [표2]는 inductive 시나리오에서 inmo를 Light-GCN에 붙였을 때 가장 우수한 성능을 보였음을 다른 baseline과 비교하여 보여준다. [표1]은 간선(interaction)을 추가했을 때, [표2]는 node(user, item)을 추가했을 때의 시나리오다.
- [표3]은 Light-GCN과 비교할때 GTN의 우수한 성능을 보여준다.
- ∴ gtn(gtcf)은 Light-gcn과 비교하여 proper smoothness를 모델링했기 때문에 더 정확한 임베딩을 얻을 수 있다. 따라서 더 좋은 성능 뿐 아니라 random interaction 등에 더 강인한 embedding propagation을 할 수 있다. 그리고 Light-gcn과 gtn 모두 임베딩 록업 테이블로 초기화된 임베딩을 학습시킨다. inmo를 Light-gcn에 붙였을 때, 임베딩 록업 테이블을 대신해 inductive한 방식으로 임베딩을 생성하고, 이 임베딩을 전파시켰을 때 더 좋은 성능을 보였다. 따라서 다음과 같은 가설을 세울 수 있다. inmo를 통해 inductive한 방식으로 생성한 임베딩을 gtn에 이용할 때 inductive 시나리오에서 Light-gcn에 inmo를 붙였을 때보다 더 좋은 성능을 기대할 수 있다.

Table 3: Performances in the inductive recommendation scenario with new interactions.

	Gowalla			Yelp			Amazon-book		
	Recall@20	Precision@20	NDCG@20	Recall@20	Precision@20	NDCG@20	Recall@20	Precision@20	NDCG@20
INMO-LGCN-retrain	20.17(± 0.11)	5.36(± 0.04)	15.41(± 0.10)	10.26(± 0.03)	2.25(± 0.01)	6.51(± 0.02)	14.28(± 0.05)	3.01(± 0.01)	9.86(± 0.03)
Mult-VAE	16.68(± 0.08)	4.40(± 0.01)	12.60(± 0.05)	9.16(± 0.06)	2.06(± 0.01)	5.86(± 0.03)	11.79(± 0.06)	2.46(± 0.01)	8.11(± 0.04)
Mult-VAE-new	17.03(± 0.06)	4.47(± 0.02)	12.89(± 0.03)	9.49(± 0.04)	2.11(± 0.01)	6.07(± 0.02)	12.30(± 0.05)	2.55(± 0.01)	8.46(± 0.02)
IMC-GAE	14.02(± 0.05)	3.66(± 0.02)	10.61(± 0.07)	5.68(± 0.04)	1.24(± 0.01)	5.57(± 0.03)	6.80(± 0.03)	1.50(± 0.01)	4.52(± 0.03)
IMC-GAE-new	14.39(± 0.09)	3.74(± 0.03)	10.91(± 0.09)	5.85(± 0.06)	1.28(± 0.02)	5.68(± 0.04)	7.22(± 0.02)	1.58(± 0.01)	4.80(± 0.03)
LightGCN	17.66(± 0.24)	4.67(± 0.06)	13.41(± 0.15)	8.58(± 0.07)	1.93(± 0.02)	5.48(± 0.06)	10.67(± 0.07)	2.27(± 0.02)	7.14(± 0.06)
LightGCN-new	17.95(± 0.24)	4.73(± 0.06)	13.53(± 0.16)	8.96(± 0.08)	1.98(± 0.02)	5.69(± 0.06)	11.65(± 0.08)	2.46(± 0.02)	7.80(± 0.07)
IDCF-LGCN	12.54(± 0.21)	3.39(± 0.07)	9.45(± 0.17)	5.16(± 0.06)	1.26(± 0.01)	3.34(± 0.03)			
IDCF-LGCN-new	12.93(± 0.29)	3.46(± 0.08)	9.69(± 0.20)	5.43(± 0.08)	1.31(± 0.02)	3.52(± 0.05)			
INMO-MF	16.66(± 0.08)	4.49(± 0.03)	12.81(± 0.12)	8.45(± 0.05)	1.89(± 0.01)	5.37(± 0.03)	11.30(± 0.04)	2.42(± 0.00)	7.76(± 0.01)
INMO-MF-new	17.45(± 0.08)	4.65(± 0.04)	13.37(± 0.13)	8.98(± 0.06)	1.97(± 0.01)	5.70(± 0.04)	12.21(± 0.06)	2.57(± 0.01)	8.32(± 0.07)
INMO-LGCN	18.25(± 0.05)	4.92(± 0.02)	14.03(± 0.06)	9.23(± 0.06)	2.05(± 0.01)	5.87(± 0.04)	12.16(± 0.05)	2.64(± 0.01)	8.39(± 0.01)
INMO-LGCN-new	19.21(± 0.04)	5.05(± 0.02)	14.51(± 0.03)	9.58(± 0.09)	2.07(± 0.01)	6.03(± 0.05)	13.44(± 0.04)	2.79(± 0.00)	9.02(± 0.03)
INMO-LGCN*-new	18.61(± 0.19)	4.92(± 0.05)	14.13(± 0.15)	9.63(± 0.07)	2.07(± 0.01)	6.06(± 0.05)	13.01(± 0.07)	2.71(± 0.02)	8.76(± 0.06)

[11]

Table 4: Performances in the inductive recommendation scenario with new users and new items.

	Gowalla			Yelp			Amazon-book		
	New User	New Item	Over All	New User	New Item	Over All	New User	New Item	Over All
INMO-LGCN-retrain	14.01(± 0.42)	16.20(± 0.20)	15.41(± 0.10)	6.21(± 0.07)	13.21(± 0.10)	6.51(± 0.02)	14.73(± 0.12)	14.91(± 0.19)	9.86(± 0.03)
Popular	1.54(± 0.12)	0.91(± 0.06)	2.10(± 0.03)	1.04(± 0.03)	1.91(± 0.05)	1.01(± 0.02)	0.55(± 0.02)	0.82(± 0.03)	0.70(± 0.01)
Mult-VAE	10.77(± 0.31)		12.58(± 0.08)	4.93(± 0.07)		5.70(± 0.05)	9.12(± 0.06)		7.87(± 0.04)
IMC-GAE	8.42(± 0.15)	9.25(± 0.21)	9.81(± 0.08)	2.57(± 0.03)	7.54(± 0.11)	3.25(± 0.03)	4.91(± 0.35)	5.12(± 0.15)	4.19(± 0.05)
IMC-LGCN	10.38(± 0.31)	10.90(± 0.09)	13.24(± 0.12)	4.67(± 0.04)	10.74(± 0.08)	5.57(± 0.03)	7.18(± 0.19)	7.07(± 0.16)	6.39(± 0.07)
IDCF-LGCN	8.29(± 0.18)	8.60(± 0.13)	9.40(± 0.09)	3.28(± 0.04)	7.77(± 0.10)	3.48(± 0.06)			
INMO-MF	10.85(± 0.24)	10.92(± 0.14)	13.10(± 0.06)	4.85(± 0.24)	10.73(± 0.25)	5.50(± 0.05)	1.89(± 0.66)	0.63(± 0.26)	1.56(± 0.59)
INMO-LGCN	12.36(± 0.38)	13.62(± 0.08)	14.52(± 0.11)	5.75(± 0.08)	12.17(± 0.05)	6.13(± 0.02)	9.05(± 0.05)	7.99(± 0.27)	7.94(± 0.07)
INMO-LGCN*	10.95(± 0.28)	11.07(± 0.10)	13.49(± 0.05)	5.56(± 0.08)	12.16(± 0.07)	6.10(± 0.02)	7.29(± 0.16)	6.78(± 0.07)	7.20(± 0.03)

“\”: Mult-VAE cannot handle the inductive scenario with new items and IDCF cannot apply to large datasets.

[12]

+ ::

Table 2: The comparison of overall performance.

Datasets		Gowalla		Yelp2018		Amazon-Book		LastFM	
Metrics		Recall@20	NDCG@20	Recall@20	NDCG@20	Recall@20	NDCG@20	Recall@20	NDCG@20
Method	MF	0.1299	0.111	0.0436	0.0353	0.0252	0.0198	0.0725	0.0614
	NeuCF	0.1406	0.1211	0.045	0.0364	0.0259	0.0202	0.0723	0.0637
	GC-MC	0.1395	0.1204	0.0462	0.0379	0.0288	0.0224	0.0804	0.0736
	NGCF	0.156	0.1324	0.0581	0.0475	0.0338	0.0266	0.0774	0.0693
	Mult-VAE	0.1641	0.1335	0.0584	0.045	0.0407	0.0315	0.078	0.07
	DGCF	0.1794	0.1521	0.064	0.0522	0.0399	0.0308	0.0794	0.0748
	LightGCN	0.1823	0.1553	0.0649	0.0525	0.042	0.0327	0.085	0.076
GTN (Ours)		0.187	0.1588	0.0679	0.0554	0.045	0.0346	0.0932	0.0857
Relative Improvement (%)		2.59	2.26	4.62	5.59	7.15	5.95	9.61	12.77

[13]